



Statistics for Engineers
TI0111

HOMEWORK I

NOME COMPLETO: GABRIEL PONTES RISTAU

NUMERO DE MATRICULA: 475740

Objectivo

O objetivo do segundo homework é revisar e familiarizar-se com os conceitos de probabilidade e variáveis aleatórias discretas e contínuas. Podem consultar os slides das aulas para os conceitos teóricos e os códigos em R para a parte computacional.

1 Questão 1

Em um restaurante muito frequentado, aproximadamente 70

1. Determine a função de distribuição de X .
2. Construa os gráficos da função massa de probabilidade (PMF) e da função distribuição acumulada (CDF) de X .
3. Calcule o valor esperado, a variância e o desvio padrão de X .
4. Calcule as probabilidades:
 - (a) $P(X \geq 20)$;
 - (b) $P(30 < X < 43)$;
 - (c) $P(X = 31)$.
5. Suponha que o restaurante estoque sobremesas com base na demanda esperada. Discuta como o uso da distribuição de X pode ajudar a reduzir desperdícios e evitar faltas de produto.
6. Discuta como mudanças em p (por exemplo, $p = 0.8$) ou em n afetariam a forma da distribuição e as probabilidades associadas a X .

Solucionário da Questão 1

Nesta questão, analisei o número de clientes que pedem sobremesa em um restaurante muito frequentado. Dessa forma, cada cliente de forma independente acaba pedindo a sobremesa com probabilidade de $p = 0,7$. Também levei em consideração que uma amostra é $n = 50$ clientes e defini a variável aleatória X como o número de clientes que pedem sobremesa nessa amostra.

Item 1. Definição da distribuição de X

Como cada cliente pode ser modelado como um experimento de Bernoulli, no caso de pedir sobremesa ou não, e os clientes são independentes, dá para acabar concluindo que X segue uma distribuição Binomial. Assim,

$$X \sim \text{Binomial}(n = 50, p = 0,7).$$

A função massa de probabilidade (PMF) de X é dada por:

$$P(X = x) = \binom{50}{x} (0,7)^x (0,3)^{50-x}, \quad x = 0, 1, \dots, 50.$$

Item 2. Gráficos da PMF e da CDF

Utilizei a linguagem R, que foi a estipulada pela professora e a linguagem da disciplina, para construir os gráficos da função massa de probabilidade (PMF) e da função distribuição acumulada (CDF). Nisso o gráfico da PMF mostra a probabilidade associada a cada valor possível de X , enquanto a CDF representa a probabilidade acumulada $P(X \leq x)$. Por fim, os gráficos montados ajudam a visualizar o comportamento da distribuição Binomial neste contexto do Item 2.

Item 3. Valor esperado, variância e desvio padrão

Para uma variável aleatória com distribuição Binomial, as medidas teóricas são conhecidas:




Figure 1: CDF




Figure 2: PMF

$$E(X) = np, \quad Var(X) = np(1 - p).$$

Substituindo $n = 50$ e $p = 0,7$, obtive:

$$E(X) = 50 \times 0,7 = 35,$$

$$Var(X) = 50 \times 0,7 \times 0,3 = 10,5,$$

$$DP(X) = \sqrt{10,5} \approx 3,24.$$

Com isso, esses valores acabam indicando que, em média, cerca de 35 clientes pedem sobremesa, com uma variação moderada em torno desse valor.

Item 4. Cálculo de probabilidades

Utilizando a função de distribuição acumulada da Binomial, deu para calcular as seguintes probabilidades:

- (a) $P(X \geq 20)$, calculada como $1 - P(X \leq 19)$;
- (b) $P(30 < X < 43)$, equivalente a $P(31 \leq X \leq 42)$;
- (c) $P(X = 31)$, obtida diretamente pela função massa de probabilidade.

Esses cálculos foram realizados no R utilizando as funções `pbinom()` e `dbinom()`.

Item 5. Aplicação prática

A distribuição de X pode ser utilizada para auxiliar o restaurante no planejamento do estoque de sobremesas. Como o valor esperado é 35, o restaurante pode usar esse valor como referência, adicionando uma margem baseada no desvio padrão para reduzir o risco de falta de produtos ou desperdício. Dessa forma, decisões mais eficientes podem ser tomadas com base em probabilidades.




Figure 3: PMF de X Binomial(100, 0.7

Item 6. Efeito de mudanças em p e n

Analisei também como mudanças nos parâmetros afetam a distribuição de X , nisso um aumento em p (por exemplo, se a sobremesa se tornar mais popular) desloca a distribuição para a direita, aumentando a média, já um aumento em n torna a distribuição mais concentrada e aproximadamente simétrica, aproximando-se de uma distribuição normal. Esses efeitos foram visualizados por meio de gráficos gerados no R.

2 Questão 2

Um site realiza uma pesquisa online e oferece uma recompensa a um usuário selecionado aleatoriamente. Cada um dos 10^7 visitantes diários tem, independentemente, probabilidade $p = 10^{-7}$ de ganhar a recompensa.

1. Encontre uma aproximação simples e adequada para a PMF do número de vencedores em um dia, X . Justifique a adequação da aproximação para os valores dados de n e p .
2. Calcule $\mathbb{E}[X]$ e $\text{Var}(X)$ usando a distribuição exata e a aproximada. Comente sobre a similaridade dos resultados.
3. Suponha que você ganhe a recompensa, mas que possa haver outros vencedores. Seja $W \sim \text{Pois}(1)$ o número de vencedores além de você. Se houver vários vencedores, o prêmio é sorteado aleatoriamente entre todos. Encontre a probabilidade de você receber o prêmio.
4. Gere um grande número de simulações diárias para o número de vencedores. Crie uma comparação visual entre os resultados empíricos e a aproximação escolhida. Descreva o que a visualização indica sobre a qualidade da aproximação.

Solucionário da Questão 2

Nesta questão, analisei o número de usuários que ganham uma recompensa em um site que realiza uma pesquisa online diariamente, com isso, cada um dos 10^7 visitantes diários tem, de forma independente, probabilidade $p = 10^{-7}$ de ganhar a recompensa. Por fim, defini a variável aleatória X como o número de vencedores em um dia.

Item 1. Aproximação da distribuição de X

Inicialmente, a variável X segue exatamente uma distribuição Binomial, pois representa o número de sucessos em um grande número de tentativas independentes. Assim,

$$X \sim \text{Binomial}(n = 10^7, p = 10^{-7}).$$

Entretanto, como o número de tentativas é extremamente grande e a probabilidade de sucesso é muito pequena, utilizei a aproximação de Poisson para simplificar a análise, nesse caso, o parâmetro da distribuição de Poisson é dado por:

$$\lambda = np = 10^7 \times 10^{-7} = 1.$$

Portanto, dá para concluir que a distribuição de X pode ser bem aproximada por:

$$X \approx \text{Poisson}(1).$$

Sendo assim, essa aproximação é apropriada, pois se trata de um cenário clássico de eventos raros.

Item 2. Valor esperado e variância

Em seguida, calculei o valor esperado e a variância de X tanto pela distribuição Binomial exata quanto pela aproximação de Poisson.

Para a distribuição Binomial, tem-se:

$$E(X) = np = 1,$$

$$Var(X) = np(1 - p) \approx 1.$$

Já para a distribuição de Poisson com parâmetro $\lambda = 1$:

$$E(X) = \lambda = 1,$$

$$Var(X) = \lambda = 1.$$

Notei que os valores obtidos são praticamente idênticos, o que reforça a qualidade da aproximação de Poisson neste problema.

Item 3. Probabilidade de realmente receber a recompensa

Supondo que eu tenha ganhado a recompensa, dá para considerar que a possibilidade de existirem outros vencedores no mesmo dia, a partir disso, modelei o número de vencedores além de mim por uma variável aleatória $W \sim \text{Poisson}(1)$. Caso haja múltiplos vencedores, o prêmio é sorteado aleatoriamente entre todos.

Assim, a probabilidade de eu efetivamente receber a recompensa é dada por:

$$P(\text{receber o prêmio}) = \mathbb{E} \left[\frac{1}{W + 1} \right].$$

Essa esperança pode ser calculada por meio da soma:

$$P(\text{receber o prêmio}) = \sum_{w=0}^{\infty} \frac{1}{w + 1} P(W = w).$$

O valor obtido é aproximadamente 0,63, indicando que, mesmo ganhando, recebo o prêmio em cerca de 63% das vezes.

Item 4. Simulação e comparação com a aproximação

Para verificar a qualidade da aproximação de Poisson, realizei uma simulação de um grande número de dias, gerando o número de vencedores diários a partir de uma distribuição Poisson com parâmetro $\lambda = 1$, em seguida, comparei

as frequências empíricas com as probabilidades teóricas da distribuição de Poisson.

A visualização mostrou que os valores simulados se alinham muito bem com a distribuição teórica, confirmando que a aproximação de Poisson fornece uma descrição adequada do número de vencedores diários.

Conclusão

Conclui-se que a aproximação de Poisson é plenamente adequada para este problema, pois simplifica os cálculos sem perda relevante de precisão. Além disso, tanto os valores teóricos quanto as simulações indicam que o comportamento do número de vencedores é bem descrito por uma distribuição Poisson com parâmetro igual a 1.

3 Questão 3

A temperatura em regime estacionário de uma CPU multicore segue uma distribuição normal com média $\mu = 62,^{\circ}\text{C}$ e desvio-padrão $\sigma = 3.5,^{\circ}\text{C}$. O objetivo é simular medições de temperatura e analisar suas propriedades estatísticas.

1. Crie uma função que gere valores normalmente distribuídos usando a transformação de Box–Muller:

(a) Gere $U_1, U_2 \sim \text{Unif}(0, 1)$ independentes.

(b) Calcule $[Z_1 = \sqrt{-2 \ln(U_1)} \cos(2\pi U_2), \quad Z_2 = \sqrt{-2 \ln(U_1)} \sin(2\pi U_2)].$

(b) Converta para a temperatura da CPU: $T = 62 + 3.5Z$.

2. Gere 1,000 medições de temperatura usando seu gerador e mais 1,000 usando o gerador normal embutido do R.
3. Para ambos os conjuntos de dados, calcule:
 - (a) Média amostral;
 - (b) Desvio-padrão amostral;
 - (c) Temperatura mínima e máxima;

- (d) Probabilidades empírica e teórica $P(T > 68)$;
 - (e) Probabilidades empírica e teórica $P(60 < T < 65)$;
 - (f) Probabilidade teórica $P(T > 75)$.
4. Verifique se algum dos conjuntos simulados contém valores acima de 75°C e explique por que eventos raros requerem grandes tamanhos de amostra.
 5. Visualize os resultados com histogramas e sobreponha a PDF normal teórica.
 6. Discuta os resultados, comparando as distribuições empíricas com a normal teórica e avaliando diferenças entre os dois geradores de números aleatórios.

Questão 3

Nesta questão, analisei o comportamento da temperatura de uma CPU multicore em regime estacionário, considerando que, sob condições normais de operação, a temperatura segue uma distribuição Normal com média $\mu = 62^\circ\text{C}$ e desvio padrão $\sigma = 3,5^\circ\text{C}$. O objetivo foi simular medições dessa temperatura e analisar suas propriedades estatísticas.

Item 1: Geração de variáveis normais via Box–Muller

Inicialmente, construí um gerador de números aleatórios com distribuição Normal padrão utilizando a transformação de Box–Muller, sem recorrer à função `rnorm()` do R. Para isso, gerei duas variáveis aleatórias independentes com distribuição Uniforme no intervalo $(0, 1)$, denotadas por U_1 e U_2 .

A partir dessas variáveis, utilizei as fórmulas da transformação de Box–Muller:

$$Z_1 = \sqrt{-2 \ln(U_1)} \cos(2\pi U_2), \quad Z_2 = \sqrt{-2 \ln(U_1)} \sin(2\pi U_2).$$

Os valores Z_1 e Z_2 obtidos são independentes e seguem uma distribuição Normal padrão, isto é, $Z_1, Z_2 \sim \mathcal{N}(0, 1)$. Em seguida, concatenei esses valores para formar um vetor de observações normalmente distribuídas.

Para obter valores compatíveis com a distribuição da temperatura da CPU, apliquei a transformação linear:

$$T = 62 + 3,5Z,$$

onde Z representa uma variável Normal padrão. Dessa forma, os valores simulados de T seguem aproximadamente uma distribuição $\mathcal{N}(62, 3,5^2)$.

Item 2: Simulação de medições e análise estatística

Nessa parte, utilizei o gerador baseado em Box–Muller para simular 1.000 medições da temperatura da CPU. Além disso, gerei um segundo conjunto de 1.000 observações utilizando o gerador de números aleatórios nativo do

R, por meio da função `rnorm()`, com a mesma média e desvio padrão, tudo com o objetivo de comparar os resultados obtidos pelos dois métodos.

Item 3. Estatísticas descritivas

Para ambos os conjuntos de dados simulados, calculei as seguintes estatísticas descritivas:

- média amostral;
- desvio padrão amostral;
- temperatura mínima e máxima observadas.

Os resultados mostraram que, em ambos os casos, as médias ficaram próximas de 62°C e os desvios padrão próximos de $3,5^{\circ}\text{C}$, conforme esperado teoricamente, nisso as pequenas diferenças observadas são atribuídas à variabilidade amostral.

Item 4. Probabilidades empíricas e teóricas

Em seguida, calculei probabilidades empíricas e teóricas para alguns eventos de interesse. As probabilidades empíricas foram estimadas pela proporção de observações simuladas que satisfazem o evento considerado, enquanto as probabilidades teóricas foram obtidas a partir da função de distribuição acumulada da Normal.

Considere os seguintes casos:

- $P(T > 68)$;
- $P(60 < T < 65)$;
- $P(T > 75)$ (probabilidade teórica).

Observei que as probabilidades empíricas ficaram bastante próximas das probabilidades teóricas nos dois primeiros casos. Já para o evento $T > 75^{\circ}\text{C}$, notando-se que a probabilidade teórica é extremamente pequena, o que explica a ausência ou raridade de observações acima desse valor em apenas 1.000 simulações. Eventos raros exigem amostras muito maiores para serem observados empiricamente.

Item 5. Visualização dos resultados

Para complementar a análise, construí histogramas das temperaturas simuladas para os dois métodos. Em seguida, sobrepus a função densidade de probabilidade da distribuição Normal teórica com média 62 e desvio padrão 3,5.

Os histogramas apresentaram formato aproximadamente simétrico e compatível com a curva Normal teórica, indicando que ambos os métodos de geração produzem resultados consistentes com o modelo assumido.

Conclusão

Por fim dá para concluir que a transformação de Box–Muller é eficaz para gerar variáveis aleatórias normalmente distribuídas a partir de números Uniformes, além disso, os resultados obtidos com o gerador manual e com o gerador nativo do R são estatisticamente equivalentes. A simulação mostrou-se uma ferramenta útil para analisar o comportamento térmico da CPU, avaliar eventos extremos e compreender melhor o papel dos geradores de números aleatórios em estudos estatísticos.

A Appendix A: R Code

B Appendix B: Use of AI Tools